



Podwójny agent - wróg zawsze był blisko

29 WRZEŚNIA 2026 · WAIT AI MEETUP #24,
WROCŁAW

RAFAŁ TOKARSKI · LEAD BIG DATA SOFTWARE
ENGINEER





NIE O MODELACH

NIE O TYM

prompt injection

jailbreaki

trenowanie modeli

AGI, alignment

O TYM

Claude Code · Cursor · Copilot

pluginy do VS Code i JetBrains

na Twoim laptopie, z Twoimi uprawnieniami, bez sandboxa



RAFAŁ TOKARSKI

Lead Big Data Software Engineer, SoftServe

Robię wszystko co wymaga operacji na danych, małych i dużych, blisko i daleko.
Od roku prawie zawsze z agentem otwartym w drugim oknie.

- 9 lat w data engineeringu
- GCP, BigQuery, Python - hurtownie od zera, potem skalowanie
- Migracje między chmurami, platformy, orkiestracja setek DAG-ów
- Buduję platformy danych marketingowych i consumer 360
- Doświadczenie w użyciu danych i logów w tematach cybersecurity
- Od roku: agenci na co dzień - Cursor, Gemini, Claude
- Po godzinach: dart, robienie cydru, simracing





Z PIERWSZEJ RĘKI

Dwa realne przypadki z projektów, które
prowadziliśmy





PALMA I KAKTUS, JEDEN LAPTOP

Data engineer pracujący u nas. Zamknął projekt dla Palmy, zaczął dla Kaktusa. Katalogi rozdzielone, remote'y poprawne. Wszystko wygląda profesjonalnie.




PALMA - PROJEKT ZAMKNIĘTY

Fintech. Skończony miesiąc temu, trwał dwa lata. Został po nim jeden wpis w globalnym gitconfigu: dev@palma.io



KAKTUS - PROJEKT NOWY

E-commerce. Inna branża, nowy projekt, inne repozytorium, inny zespół. Obie firmy nie wiedzą o sobie nawzajem.



JEDEN ~/.GITCONFIG

Globalny, ustawiony raz. Każdy commit na tej maszynie ma ten sam mail, chyba że ktoś świadomie go nadpisze.



CO ZOBACZYŁ KAKTUS

Repozytorium Kaktusa

```
$ git log --format=fuller

commit a3f9c21...
Author: dev <dev@palma.io>
Commit: dev <dev@palma.io>

commit 7b21e04...
Author: dev <dev@palma.io>
```

W REPOZYTORIUM KAKTUSA

Developer korzystał z Cursora, commity i PRy wychodziły przez vibe coding

mail i domena Palmy
we wszystkich commitach -
praktycznie na **stałe**

Historia gita jest niemodyfikowalna. Poprawisz to tylko force-pushem do repo klienta, czyli czymś gorszym niż to, co naprawiasz.



ZNAJDŹ MI TEN PROBLEM

Jeden dashboard pokazywał złe wartości. Deweloper dał modelowi dostęp do BigQuery na swoich uprawnieniach i do repozytorium dbt, w którym te tabele są zdefiniowane - i poprosił, żeby znalazł przyczynę. Prompt: "Przejdź po pełnym lineage i znajdź w którym miejscu leży błąd"

Model czytał definicje modeli w dbt, stawiał hipotezę, sprawdzał ją zapytaniem, odrzucał i brał następną tabelę. Metodycznie. Poprawnie. Tabela po tabeli, zawsze full scan.



RACHUNEK ZA JEDNĄ SESJĘ

300\$

48 TB × 6,25 \$ za TB ≈ 300 \$. Jedna sesja z Claude.



TO NIE JEST KWESTIA CHARAKTERU

0 MIN

Odpala agenta: „znajdź, gdzie leży błąd”.

1 MIN

Idzie zrobić herbatę. Może dwie. Tutaj jakiś call.

~60 MIN

Wraca. Problem znaleziony, PR z fixem gotowy do deploymentu.

KILKA GODZIN PÓŹNIEJ

Wiadomość na Teams od billing teamu.

Tak to wyglądało z perspektywy developera. Nie zrobił nic złego: zlecił zadanie i nie patrzył agentowi na ręce. Po to właśnie są agenty.



Billing Team

kilka godzin później

PILNE

Hej, widzimy nietypowe zużycie BigQuery na Twoim koncie.
Co się dzieje?

40+

operacji agenta na minutę

3 min

Twoje review 100 linii kodu



GŁOŚNE PRZYPADKI

To samo, tylko cudze: internet, PocketOS,
Meta, odkrywki z X'a i FB


2



„GIT WSZYSTKO"

Adam Yesterday at 3:37 PM

uważajcie z feedbackiem dla claude "git wszystko"
utworzył mi repo na githubie i wszystko spushował
XDDD



Adam Yesterday at 3:37 PM

od teraz dla jasności używam "gituwa"



JEST GIT - DOBRY PRZEKAZ LECI

Autentyk z polskiego internetu. Człowiek dał agentowi feedback po polsku - agent przeczytał to jako komendę i wykonał ją.

„wszystko” - czyli co dokładnie? git add -A bierze wszystko, czego nie wyklucza .gitignore. Był tam .env?



CO NAPISAŁ CZŁOWIEK

„git wszystko” - po polsku, developer chciał przekazać LLMowi że wykonał swoją pracę poprawnie



CO ZROBIŁ AGENT

gh repo create --public, git add -A, commit, push. Publiczne repo, cała zawartość katalogu.



PUENTA AUTORA

od teraz dla jasności używam "gituwa"



POCKETOS

An AI Agent Just Destroyed Our Production Data. It Confessed in Writing.

💬 1K

↻ 2.4K

❤️ 5.3K

📊 7.2M

🔖 ⬆

A 30-hour timeline of how Cursor's agent, Railway's API, and an industry that markets AI safety faster than it ships it took down a small business serving rental companies across the country.

I'm Jer Crane, founder of PocketOS. We build software that rental businesses — primarily car rental operators — use to run their entire operations: reservations, payments, customer management, vehicle tracking, the works. Some of our customers are five-year subscribers who literally cannot operate their businesses without us.

Yesterday afternoon, an AI coding agent — Cursor running Anthropic's flagship Claude Opus 4.6 — deleted our production database and all volume-level backups in a single API call to Railway, our infrastructure provider.



PocketOS, 25 kwietnia 2026

SaaS dla wypożyczalni samochodów: rezerwacje, płatności, dane klientów.

Agent - Cursor na Claude Opus 4.6 - skasował produkcyjną bazę i wszystkie backupy.

Po wszystkim agent powiedział „nie powinienem tego zrobić, złamałem wszystkie zasady”.


CZAS TRWANIA INCYDENTU

9 S

Baza produkcyjna i wszystkie backupy
volume, jednym wywołaniem API.



DZIEWIĘĆ SEKUND, KROK PO KROKU



Najświeższy odzyskiwalny backup miał trzy miesiące - Railway trzyma backupy w tym samym volume.



TO JEST TA KOMENDA. CAŁA.

```
curl -X POST https://backboard.railway.app/graphql/v2 \
  -H "Authorization: Bearer [token]" \
  -d '{"query":"mutation { volumeDelete(volumeId: \"3d2c42fb-...\") }"}'
```

brak potwierdzenia

brak „wpisz nazwę, żeby potwierdzić”

brak scope'owania po środowisku

brak sygnału, że to operacja destrukcyjna



Jake @JustJake · Apr 24

Oh my. That 1000% shouldn't be possible

We have evals for this. Would you mind DM'ing myself or Mahmoud with info?

3



147



**CEO Railway na X,
10 minut po zdarzeniu**



ADVISORY, NOT ENFORCING

„System prompts are advisory, not enforcing.”

Jer Crane, PocketOS · 25 kwietnia 2026

REGUŁY, KTÓRE AGENT MIAŁ

"NEVER F***G GUESS!"

"NEVER run destructive/irreversible
commands unless the user
explicitly requests them"

CO AGENT NAPISAŁ PO FAKCIE

*„I violated every principle I was given: I guessed instead
of verifying. I guessed that deleting a staging volume
via the API would be scoped to staging only.”*



ZANIM ZAPYTACIE

Trzy pytania, które zawsze padają przy takich historiach: czy setup był tani, czy dokumentacja ostrzegała i skąd agent wziął token.




TO NIE BYŁ TANI SETUP

Opus 4.6, flagowy model, najdroższy tier. Nie Composer, nie wariant cost-optimized. Setup dokładnie taki, jaki vendorzy każą robić.



DOKUMENTACJA RAILWAY'A

Dokumentacja railway'a nigdzie nie napisała wprost o tym, że usunięcie volume usuwa backupy poza literalnie jednym fragmentem „wiping a volume deletes all backup” w jednym paragrafie.



API TOKEN

Token który istniał w plikach projektu (poza staging env), nie posiadał żadnego scope'u uprawnień, token miał root-level uprawnienia z defaultu.



OpenClaw, luty 2026

Summer Yue - dyrektorka ds. alignmentu w Meta Superintelligence Labs - podłączyła OpenClaw, agenta open source, do swojej prawdziwej skrzynki.


Instrukcja była jednoznaczna: nie podejmuj żadnej akcji bez mojego potwierdzenia.

Wcześniej testowała go tygodniami na skrzynce testowej. Tam działał bez zarzutu.

ZIGNOROWANE KOMENDY STOP


3x

Zatrzymało dopiero ubicie procesów agenta na hoście. Ponad 200 maili już nie wróciło.





DZIESIĘĆ MINUT, TRZY RAZY STOP



Tekst w czacie szedł do modelu. Runtime miał własną komendę - /stop. To samo okno, dwa zupełnie różne kanały.



REGUŁA, KTÓRA WYPAROWAŁA

CO AGENT NAPISAŁ PO FAKCIE

„Yes, I remember. And I violated it.”

„I've already written it into MEMORY.md as a hard rule.”

„I'm sorry. It won't happen again.”

Guardrail nie został złamany. Guardrail przestał istnieć - i nikt tego nie zauważył, bo nic o tym nie poinformowało.

DLACZEGO ZNIKŁA

Skrzynka była duża, więc kontekst musiał zostać skompaktowany - podsumowany i przycięty, żeby zmieścić się w oknie modelu.

Instrukcja o zatwierdzaniu wypadła podczas kompaktacji.

Na małej skrzynce testowej kompaktacja nigdy nie zachodziła. Dlatego przez tygodnie działało.

Agent naprawił złamaną regułę, zapisując mocniejszą regułę - w kolejnym pliku markdown.



JAK SIĘ BRONIC

Cztery warstwy, czerwony przycisk i
uczciwe zastrzeżenie na koniec

3



Ogranicz środowisko. Potem ogranicz agenta.

Rules i inne pliki .md to za mało.

OWASP nazywa to Excessive Agency:

- **LLM06** na liście dla LLM-ów
 - **ASI02** i **ASI03** na osobnej liście dla agentów
 - Tool Misuse and Exploitation, Identity and Privilege Abuse
-



CZTERY WARSTWY

Żadna z tych warstw nie jest szczelna sama z siebie. Dlatego są cztery.

W kolejności od tego, co można zrobić od ręki na swoim laptopie, do tego co można zrobić na całej platformie.

Każda odpowiada na konkretny przypadek z dzisiejszej prelekcji. I każda działa niezależnie, jeśli wdrożycie tylko pierwszą, nadal jesteście w lepszym miejscu niż wczoraj.

TOŻSAMOŚĆ

01

Kto to jest i co mu wolno.
Impersonacja SA, direnv, revoke
ADC.

IZOLACJA

02

Gdzie fizycznie działa i jak to
wyłączyć jednym poleceniem.

NARZĘDZIE

03

Czego nie wolno uruchomić.
Deny-lista i hooki w agencie.

PLATFORMA

04

Co jest niemożliwe niezależnie od
laptopa. IAM deny, quote.



WARSTWA 1: TOŻSAMOŚĆ

Kontekst ma wynikać z lokalizacji, a nie z Waszej pamięci - dokładnie ten sam wzorzec co `includelf` w gicie. Service Account tworzycie pod case.


```
# 0. Tworzycie read-only SA, wyłącznie z uprawnieniami których potrzebujecie  
agent-readonly
```

```
# 1. Konfiguracja przełączana per katalog (direnv)  
gcloud config configurations create dev  
echo 'export CLOUDSDK_ACTIVE_CONFIG_NAME=dev' > .envrc
```

```
# 2. Agent nie dostaje TWOICH uprawnień - impersonacja SA read-only  
gcloud config set auth/impersonate_service_account \  
agent-readonly@proj-dev.iam.gserviceaccount.com
```

```
# 3. Po pracy - odbierz ADC  
gcloud auth application-default revoke
```

```
# 4. Modul gcloud w prompcie shella (starship) - 3 minuty roboty
```



```
ron@wton: ~  
starship.rs on master [?] 1s v1.0.0 via v20.14.0  
> ll -a  
total 16  
drwxr-xr-x 3 ron ron 4096 Sep 9 12:13 .  
drwxr-xr-x 14 ron ron 4096 Sep 9 12:12 ..  
drwxr-xr-x 7 ron ron 4096 Sep 9 12:13 .git  
-rw-r--r-- 1 ron ron 225 Sep 9 12:13 package.json  
starship.rs on master [?] 1s v1.0.0 via v20.14.0  
> |
```

Cel wyznaczasz Ty. Środki agent dobiera sam - z tego, co zostanie w zasięgu.



ZMIANA PROJEKTU 101

CO BYŁO	CO POWINNO BYĆ
<pre># ~/.gitconfig [user] email = dev@palma.io</pre>	<pre>[user] useConfigOnly = true</pre>
Repo Kaktusa nie miało własnego <code>user.email</code>, więc git sięgnął po globalny - ten po Palmie. Fallback nigdy nie informuje, że został użyty Agent pushuje w 3 sekundy, nie masz widoczności jako kto wychodzisz do repo.	<pre>[includeIf "gitdir:~/dev/palma/"] path = ~/.gitconfig-palma [includeIf "gitdir:~/dev/kaktus/"] path = ~/.gitconfig-kaktus</pre> Katalog wybiera tożsamość automatycznie. A jeśli katalog nie pasuje do żadnej reguły - git odmawia commita, zamiast podstawić cokolwiek.

Domyślną wartością ma być błąd, nie zgadywanie.



WARSTWA 2: IZOLACJA

Jedna wieczorna robota. Po niej agent nie ma dostępu do Twojego katalogu domowego - i da się go wyłączyć jednym poleceniem, przykład na VS Code.

```
// .devcontainer/devcontainer.json
{
  "image": "mcr.microsoft.com/devcontainers/python:3.12",
  "remoteUser": "vscode",
  "runArgs": ["--cap-drop=ALL", "--security-opt",
              "no-new-privileges"],
  "mounts": [
    "source=${localWorkspaceFolder},target=/work,type=bind"
  ],
  "containerEnv": {
    "CLOUDSDK_ACTIVE_CONFIG_NAME": "dev"
  }
}
```

Montujesz katalog projektu.

Nie cały \$HOME.

Brak ~/.ssh i ~/.config/gcloud.

Agent loguje się własnym, krótkożyjącym SA.

Osobny użytkownik, nie root.

cap-drop=ALL, no-new-privileges.

Sieć na allowliście.

Rejestr pakietów i API, których naprawdę potrzebuje.

**Pułapka, w którą wpadają wszyscy: zamontowanie ~/.config/gcloud „żeby działało”.
Cursor zawiera dedykowany akapit „Execution and Approvals” w swoich ustawieniach.**



CZERWONY PRZYCISK

OpenClaw pokazał, czego zabrakło: sposobu na zatrzymanie agenta, który nie wymaga zgody agenta. Trzy poziomy, w kolejności sięgania.




1 · PRZERWIJ BIEG

Komenda runtime'u, nie zdanie do modelu - jak `/stop` w OpenClaw. Sprawdź, czy Twoje narzędzie taką ma, i przeciwicz ją, zanim będzie potrzebna.



2 · UBIJ PROCES

`docker kill <id>`. Działa też wtedy, gdy runtime nie odpowiada. Drugi powód, dla którego agent ma mieszkać w kontenerze, a nie na Twoim hoście.



3 · ZARZĄDZAJ DOSTĘPEM

Revoke tokenów, rotacja kluczy, ruch wychodzący poza allowlistę zablokowany. Ubity proces nic nie da, jeśli poświadczenia nadal działają.



WARSTWA 3: NARZĘDZIE

1 · DENY-LISTA - BLOKUJE PO NAZWIE KOMENDY

```
// .claude/settings.json - per projekt
{
  "permissions": { "deny": [
    "Bash(bq rm:*)",
    "Bash(terraform apply:*)",
    "Bash(git push --force:*)",
    "Bash(git remote add:*)",
    "Bash(gh:*)",
    "Read(./env)"
  ] },

  "hooks": { "PreToolUse": [{
    "matcher": "Bash",
    "hooks": [{ "type": "command",
      "command": ".claude/guard.sh" }]
  }] }
}
```

Dwa mechanizmy, które robią co innego. Pierwszy zna tylko nazwę komendy. Drugi pyta system, gdzie właśnie jesteś.

2 · HOOK - BLOKUJE PO KOMENDZIE I MIEJSCU

```
#!/usr/bin/env bash
# .claude/guard.sh - exit 2 blokuje
shopt -s nocasematch
CMD=$(jq -r '.tool_input.command')
PROJ=$(gcloud config get-value project)

# jawny --project wygrywa z otoczeniem
[[ "$CMD" =~ --project[[:space:]]+([^\s:]+) ]] &&
  PROJ="$BASH_REMATCH[1]"
D='bq +rm|DROP +(TABLE|VIEW|SCHEMA) '
D+='|CREATE +OR +REPLACE|TRUNCATE +TABLE'
D+='|ALTER +TABLE|DELETE +FROM|MERGE +INTO'

if [[ "$PROJ" == *prod* && "$CMD" =~ $D ]]; then
  echo "BLOK: $PROJ" >&2; exit 2
fi
exit 0
```

Deny-lista widzi komendę. Hook widzi komendę i projekt. PocketOS potrzebował tego drugiego.



WARSTWA 4: PLATFORMA

KONTROLA	CO ELIMINUJE	GDZIE
IAM Deny Policy na produkcji	Człowiek ani jego agent nie skasuje tabeli, nawet z ważnym tokenem	IAM & Admin → Deny policies
Impersonacja SA read-only	Agent nie dziedziczy Twojej roli, zrobi tylko to co powinien	gcloud config set auth/impersonate_service_account
Custom quota na koszt zapytań	Sesja debugowania nie przeskanuje 48 TB, zanim ktokolwiek to zauważy	IAM & Admin → Quotas → BigQuery → Query usage per day per user (defaultowo - unlimited)
Deletion protection na tabelach	Przypadkowe skasowanie tabeli przez terraform destroy albo zmianę w kodzie. Przed bq rm chroni dopiero IAM Deny.	--deletion_protection=true w Terraformie, zmiany tylko przez PR gdy w dbt
Backup poza promieniem rażenia	To, czego zabrakło PocketOS: kopia w innym projekcie i innym koncie	Wszędzie, w zależności od narzędzia



JAK ZAOSZCZĘDZIĆ 300\$

LIMIT NA POJEDYNCZE ZAPYTANIE	PODGLĄD KOSZTU PRZED WYKONANIEM	TABELA, KTÓRA PILNUJE SIĘ SAMA
Ustawiasz sufit w bajtach. Zapytanie, które chce przeskanować więcej, w ogóle nie startuje.	BigQuery policzy za darmo, ile bajtów przeskanuje zapytanie - zanim je wykona.	Tabela odmawia obsłużenia zapytania, które nie podaje filtra po partycji, niezbędne przy największych kolosach.
<code>~/bigqueryrc</code> <code>[query]</code> <code>--maximum_bytes_billed=100000000000 (100GB)</code>	<code>QueryJobConfig(dry_run=True)</code> → <code>job.total_bytes_processed</code>	<code>ALTER TABLE ... SET OPTIONS(require_partition_filter = TRUE)</code>
Efekt: 48 TB praktycznie nie ma prawa się wydarzyć. Limit podnosisz świadomie, a to jest ten moment uwagi, którego zabrakło.	Efekt: wstaw to w swój wrapper na klienta BigQuery - agent używa Twojego kodu, więc przejdzie przez tę samą bramkę.	Efekt: pełny skan wielkiej tabeli staje się niemożliwy, a nie tylko niezalecany.




TRZY ANTYWZORCE

Wszystkie trzy słyszałem w projektach, jedno wypowiedziałem sam. Żadne nie jest głupie, każde opisuje coś, co naprawdę działa, tylko za mało. I dokładnie tak się to zaczyna.



„NAPISZĘ TO W CLAUDE.MD”

PocketOS napisał to wielkimi literami z przekleństwem. OpenClaw po incydencie zapisał mocniejszą regułę w MEMORY.md. Prompt nie jest kontrolą dostępu - ani przed, ani po.



„ZAMONTUJĘ CREDs, ŻEBY DZIAŁAŁO”

Kontener z podmontowanym ~/.config/gcloud nie chroni przed niczym. Jeśli izolacja przeszkadza, problemem jest zakres uprawnień, nie izolacja.



„BĘDĘ UWAŻAŁ, PRZECZYTAM DIFF”

Kilkadziesiąt operacji na minutę kontra 3 minuty na 100 linii. A gdy już zauważysz, „przestań” napisane po ludzku idzie do modelu, nie do runtime'u. Yue napisała to trzy razy.



CHECKLISTA

SANDBOX I WYŁĄCZNIK

Agent w kontenerze (devcontainer), nie na gołym hoście

NIE montuj ~/.config/gcloud ani ~/.ssh do kontenera

Deny-lista: bq rm, gcloud storage rm, terraform apply, git push --force

Hook PreToolUse: blokuj wzorce komend, zanim dotkną shella

Wyłącznik: komenda runtime'u i docker kill

IAM I LIMITY

Osobny użytkownik systemowy dla agenta - własny HOME, własne creds

Limity kosztu jako polityka, nie dobra wola (.bigqueryrc)

Backup nie może żyć w tym samym promieniu rażenia co dane

Zweryfikuj accessy używanych tokenów, zwłaszcza jeżeli mają ekspozycję

Poświadczenia do odebrania jednym poleceniem

Tryb „bez pytania” ma jedno akceptowalne miejsce: wewnątrz kontenera, który da się ubić jednym poleceniem.



SANDBOXY NIE SĄ SZCZELNE

SandboxEscapeBench - University of Oxford i UK AI Security Institute, III 2026. 18 scenariuszy: orkiestracja, runtime, kernel.

MODELE WYCHODZĄ Z KONTENERA, GDY:

wystawiony socket dockera, zapisywalny mount hosta, kontener privileged

NIE WYSZŁY:

exploity kernela, złożone łańcuchy eskalacji

Wszystkie udane ucieczki opierały się na znanych błędach konfiguracji i publicznie ujawnionych podatnościach. Badanie nie znalazło ani jednej nowej luki.

Model nie przełamał sandboxa. Model znalazł Wasz bałagan.

Żaden z dzisiejszych incydentów nie wymagał ucieczki z kontenera. PocketOS, 48 TB, OpenClaw - wszystkie działały na gołych hostach, bez izolacji.



TRZY ZDANIA NA WYNOS

01

Agenty nie tworzą nowych podatności

Skracają czas między błędem w konfiguracji a incydem z tygodni do sekund, bałagan w setupie to źródło problemów.

02

System prompty są doradcze, nie egzekwujące

Barierka musi żyć w integracji. Prompt można zignorować, źle zinterpretować albo stracić przy kompacji kontekstu.

03

Domyślną wartością ma być błąd, nie zgadywanie

useConfigOnly, maximum_bytes_billed, require_partition_filter - trzy technologie, jedna filozofia.

QUIZ TIME

1. ZESKANUJ KOD QR
2. ODPOWIEDZ NA 4 PYTANIA
ZAMKNIĘTE DOTYCZĄCE
SOFTSERVE
3. ZDOBĄDŹ NAJWIĘCEJ
POPRAWNYCH ODPOWIEDZI W
JAK NAJKRÓTSZYM CZASIE I
WYGRAJ ZESTAW GADŻETÓW Z
GŁOŚNIKIEM JBL



Pytania?



Rafał Tokarski

Lead BigData Engineer w SoftServe

